

Министерство образования и науки РФ
Санкт-Петербургский политехнический университет Петра Великого
Институт компьютерных наук и кибербезопасности
Высшая школа программной инженерии

**Лабораторная работа по дисциплине «Системы
искусственного интеллекта»**
Методы классификации

Студент гр. 5130904/30104

Руководитель

Аюпов Д. И.

Уткин Л. В.

Санкт-Петербург 2026


Задание 1. Наивный Байесовский классификатор (tic_tac_toe.txt и spam.csv)


Постановка задачи

Исследуйте, как объем обучающей выборки и количество тестовых данных, влияет на точность классификации в датасетах про крестики-нолики (tic_tac_toe.txt) и о спаме e-mail сообщений (spam.csv) с помощью наивного Байесовского классификатора. Постройте графики зависимостей точности на обучающей и тестовой выборках в зависимости от их соотношения.

Ход работы

Загружены датасеты tic_tac_toe.txt (958 строк) и spam.csv (4601 строка). Использован классификатор GaussianNB. Обучающая выборка последовательно увеличивалась от 1 до 80% образцов. Построены графики зависимости точности от отношения размеров тренировочной выборки к тестовой





Выводы

Максимальная точность для tic_tac_toe.txt достигается при train/test примерно равным 1.25, для spam.csv практически не меняется (около 0.82)

Для tic_tac_toe оптимально примерно равное разделение данных 55/45

Для spam модель устойчива к изменению пропорций в широком диапазоне

При слишком большой доле обучающей выборки точность снижается из-за недостаточного объема тестовых данных для объективной оценки

Задание 2. Генерация данных и Байесовский классификатор

Постановка задачи


Сгенерируйте 100 точек с двумя признаками X_1 и X_2 в соответствии с нормальным распределением так, что одна и вторая часть точек (класс -1 и класс 1) имеют параметры: мат. ожидание X_1 , мат. ожидание X_2 , среднеквадратические отклонения для обеих переменных, соответствующие вашему варианту (указан в таблице). Построить диаграммы, иллюстрирующие данные. Построить Байесовский классификатор и оценить качество классификации с помощью различных методов (точность, матрица ошибок, ROC и PR-кривые). Является ли построенный классификатор «хорошим»?

Параметры варианта:


10 14 3 19 16 4 20 80

Ход работы


Сгенерировано 100 точек с двумя признаками по нормальному распределению



Построены диаграммы рассеяния
 Построен Байесовский классификатор
 Оценка качества:
 AUC-ROC: 0.994 — отличное качество



PR-кривая для класса 1: precision стремится к 1, recall достигает 0.97
 PR-кривая для класса -1: соединяет точки (0,1) и (1,0)



Выводы

Классификатор является «хорошим», так как $AUC-ROC > 0.99$ говорит об отличной разделяющей способности. Классы хорошо разделимы благодаря выбранным параметрам распределений.

Задание 3. Метод k ближайших соседей (Glass)

Постановка задачи

Постройте классификатор на основе метода k ближайших соседей для обучающего множества Glass (glass.csv). Посмотрите заголовки признаков и классов. Перед построением классификатора необходимо также удалить первый признак Id number, который не несет никакой информационной нагрузки. а. Постройте графики зависимости ошибки классификации от количества ближайших соседей. б. Определите подходящие метрики расстояния и исследуйте, как тип метрики расстояния влияет на точность классификации. с. Определите, к какому типу стекла относится экземпляр с характеристиками: RI =1.516 Na =11.7 Mg =1.01 Al =1.19 Si =72.59 K=0.43 Ca =11.44 Ba =0.02 Fe =0.1

Ход работы

Исходные данные:

Всего 214 образцов

Из них 150 образцов использовано для обучения, остальные для теста

За. График зависимости ошибки от количества соседей

Максимальная точность достигнута при $k = 3$


При $k = 1$ и $k = 2$ точность также высокая

Спад точности наблюдается до $k = 11$

Затем рост до $k = 17$

После $k = 17$ точность преимущественно падает

График зависимости ошибки классификации от количества ближайших соседей




3b. Исследование метрик расстояния

Метрика Средняя точность

Cosine 0.70

Manhattan 0.35

Euclidean 0.30



3с. Классификация нового образца

Характеристики образца:

RI=1.516, Na=11.7, Mg=1.01, Al=1.19, Si=72.59, K=0.43, Ca=11.44, Ba=0.02, Fe=0.1

Результат предсказания: Тип стекла — 2

Выводы

Оптимальное значение $k = 3$ выбрано как точка максимума точности.

Косинусная метрика показала наилучший результат, так как она учитывает угол между векторами и менее чувствительна к масштабу признаков, чем евклидово расстояние.

Задание 4. Метод опорных векторов (SVM)

Постановка задачи

Постройте классификаторы на основе метода опорных векторов для наборов данных из файлов svmdataN.txt и svmdataNtest.txt, где N – индекс задания:

а. Постройте алгоритм метода опорных векторов с линейным ядром. Визуализируйте разбиение пространства признаков на области с помощью полученной модели (пример визуализации). Визуализируйте опорные вектора на графике с разбиением пространства, выведите их количество. Выведите матрицу ошибок классификации на обучающей и тестовой выборках.

б. Постройте алгоритм метода опорных векторов с линейным ядром. Добейтесь нулевой ошибки сначала на обучающей выборке, а затем на тестовой, путем изменения штрафного параметра. Выберите оптимальное значение данного параметра и объясните свой выбор. Всегда ли нужно добиваться минимизации ошибки на обучающей выборке?

с. Постройте алгоритм метода опорных векторов, используя различные ядра (линейное, полиномиальное степеней 1-5, сигмоидальная функция, гауссово). Визуализируйте разбиение пространства признаков на области с помощью полученных моделей. Сделайте выводы.

d. Постройте алгоритм метода опорных векторов, используя различные ядра (полиномиальное степеней 1-5, сигмоидальная функция, гауссово). Визуализируйте разбиение пространства признаков на области с помощью полученных моделей. Сделайте выводы.

e. Постройте алгоритм метода опорных векторов, используя различные ядра (полиномиальное степеней 1-5, сигмоидальная функция, гауссово). Изменяя значение параметра ядра (гамма), продемонстрируйте эффект переобучения, выполните при этом визуализацию разбиения пространства признаков на области.

Ход работы

4a. Линейное ядро

Результаты:

Точность на обучении: 0.98

Точность на тесте: 1.00

Количество опорных векторов: 11

Матрица ошибок (обучение):

	Предсказано класс 0	Предсказано класс 1
Факт класс 0	24	1
Факт класс 1	0	25

Матрица ошибок (тест):

	Предсказано класс 0	Предсказано класс 1
Факт класс 0	25	0
Факт класс 1	0	25

4b. Достижение нулевой ошибки

Результаты:

C = 1: обучение 0.98, тест 1.00

C = 500: обучение 1.00, тест 0.94

Оптимальное значение C = 1.

Обоснование: При C = 1 модель лучше обобщается, что подтверждается более высокой точностью на тестовой выборке (1.00 против 0.94). При C = 500 модель переобучается — идеально запоминает обучающие данные, но хуже работает на новых.

4c. Исследование различных ядер (200/200)

Ядро	Точность	Кол-во опорных векторов
linear	0.42	49
poly degree=1	0.42	49
poly degree=2	0.92	16
poly degree=3	0.62	44

poly degree=4	0.90	11
poly degree=5	0.54	41
rbf	0.94	25
sigmoid	0.52	39

4d-4e. Влияние параметра gamma (120/120) При gamma = 0.01:

Ядро	Точность	Кол-во опорных векторов
poly degree=1	0.6417	120
poly degree=2	0.7833	120
poly degree=3	0.5333	120
poly degree=4	0.5917	120
poly degree=5	0.4833	120
rbf	0.6583	120
sigmoid	0.6417	120

Без указания gamma

Ядро	Точность	Кол-во опорных векторов
poly degree=1	0.6500	120
poly degree=2	0.9333	51
poly degree=3	0.5167	114
poly degree=4	0.7750	65
poly degree=5	0.4917	114
rbf	0.9167	53
sigmoid	0.5833	118

При gamma = 100:

Ядро	Точность	Кол-во опорных векторов
poly degree=1	0.6250	119
poly degree=2	0.9667	4
poly degree=3	0.5167	110
poly degree=4	0.9417	4
poly degree=5	0.5417	71
rbf	0.9083	117
sigmoid	0.4500	55

Выводы

4a)

Линейное ядро показывает отличные результаты при правильно подобранных параметрах.

4b)

Не всегда нужно добиваться нулевой ошибки на обучении, так как это ведёт к переобучению. Важнее минимизировать ошибку на тестовых данных.

4c)

Лучшие результаты показали RBF (0.94), poly degree=2 (0.92) и poly degree=4 (0.90)
Линейное ядро и poly degree=1 показали одинаково низкие результаты из-за нелинейной структуры данных

Степень полинома 2 и 4 оптимальны, нечётные степени (3,5) работают хуже

Сигмоидальное ядро не подходит для этих данных

4d-e)

Параметр gamma контролирует радиус влияния одного обучающего примера. Слишком большое gamma ведёт к переобучению, слишком маленькое — к недообучению.

Задание 5. Деревья решений

Постановка задачи

Постройте классификаторы для различных данных на основе деревьев решений: а. Загрузите набор данных Glass из файла glass.csv. Постройте дерево классификации для модели, предсказывающей тип (Type) по остальным признакам. Визуализируйте результирующее дерево решения. Дайте интерпретацию полученным результатам. Является ли построенное дерево избыточным? Исследуйте зависимость точности классификации от критерия расщепления, максимальной глубины дерева и других параметров по вашему усмотрению. b. Загрузите набор данных spam7 из файла spam7.csv. Постройте оптимальное, по вашему мнению, дерево классификации для параметра yesno. Объясните, как был осуществлён подбор параметров. Визуализируйте результирующее дерево решения. Определите наиболее влияющие признаки. Оцените качество классификации.

Ход работы

5a. Набор данных Glass Исследование критериев расщепления и глубины:

Модель	Точность на тесте
Базовое дерево	0.7188
criterion='entropy'	0.6562
max_depth=3	0.5469
max_depth=5	0.5781
max_depth=10	0.7188

5b. Набор данных spam7 Подбор оптимальных параметров через GridSearchCV:

Параметры для перебора:

max_depth: 3, 5, 7, 10, 15, None

min_samples_split: 2, 5, 10, 20

min_samples_leaf: 1, 2, 4, 8

criterion: 'gini', 'entropy'

Результаты GridSearchCV:

Лучшие параметры: {'criterion': 'entropy', 'max_depth': 7, 'min_samples_leaf': 8, 'min_samples_split': 2}

Лучшая кросс-валидационная точность: 0.8677

Наиболее влияющие признаки:

Признак	Важность
dollar	0.4493
bang	0.3323

crl.tot	0.1290
money	0.0513
n000	0.0286
make	0.0095

Оценка качества на тестовой выборке:

Метрика	Значение
Accuracy	0.8838
F1-score	0.8465
Precision	0.8859
Recall	0.8104

Матрица ошибок:

	Предсказано no	Предсказано yes
Факт no	519	38
Факт yes	69	295

Выводы

5a)

Дерево без ограничения глубины ($\text{max_depth}=12$) является избыточным, так как его точность на тестовой выборке (0.7188) не превышает точность дерева с $\text{max_depth}=10$ (0.7188).

Увеличение глубины с 10 до 12 не дало прироста качества, но усложнило модель, что свидетельствует о переобучении. Оптимальной является глубина 10, обеспечивающая баланс между сложностью и точностью.

5b)

Модель показывает хорошие результаты ($F1=0.85$, $\text{Accuracy}=0.88$). Признаки dollar и bang вносят наибольший вклад в классификацию, что логично для задачи определения спама (знаки доллара и восклицательные знаки часто встречаются в спам-письмах).

Задание 6. Кредитный скоринг (bank_scoring)

Постановка задачи

Загрузите набор данных из файла bank_scoring_train.csv. Это набор финансовых данных, характеризующий физических лиц. Целевым столбцом является «SeriousDlqin2yrs», означающий, ухудшится ли финансовая ситуация у клиента. Постройте систему по принятию решения о выдаче или невыдаче кредита физическому лицу. Сделайте как минимум 2 варианта системы на основе различных классификаторов. Подберите подходящую метрику качества работы системы исходя из специфики задачи и определите, принятие решения какой системой сработало лучше на bank_scoring_test.csv.

Ход работы

Характеристика данных:

Сильный дисбаланс классов: дефолты составляют только 6.88% обучающей и 6.84% тестовой выборки

Размер train: 96,216 образцов

Размер test: 24,053 образца

Использованные классификаторы:

Decision Tree с class_weight='balanced'

Gaussian Naive Bayes

Использованные метрики качества:

AUC-ROC — основная метрика, устойчива к дисбалансу

Recall — полнота обнаружения дефолтных клиентов (ключевая метрика для кредитного скоринга)

F1-score — гармоническое среднее precision и recall

Precision — точность предсказания дефолтов

Результаты сравнения:

Метрика	Decision Tree	GaussianNB
AUC-ROC	0.8363	0.7146
F1-score	0.2999	0.0524
Recall	0.7801	0.0279
Precision	0.1856	0.4182

Анализ Decision Tree:

Находит 78% дефолтных клиентов (Recall = 0.78) — отличный показатель

Даёт много ложных тревог (Precision = 0.19)

AUC-ROC = 0.84 — хорошая разделяющая способность

Анализ GaussianNB:

Находит только 2.8% дефолтов (Recall = 0.028) — неприемлемо для кредитного скоринга

Высокая Accurasy (0.93) обманчива — модель просто предсказывает “good” почти всем

Лучший классификатор: Decision Tree — по ключевым метрикам (AUC-ROC и Recall) он значительно превосходит GaussianNB.

Выводы

Decision Tree обнаруживает 78% потенциальных дефолтников, что позволяет минимизировать риски. Низкая Precision (19%) означает, что 4 из 5 отказов в кредите будут ложными (хорошим клиентам откажут), но для банка это менее критично, чем выдать кредит ненадёжному заёмщику.