

Министерство образования и науки РФ
Санкт-Петербургский политехнический университет Петра Великого
Институт компьютерных наук и кибербезопасности
Высшая школа программной инженерии

**Лабораторная работа по дисциплине «Системы
искусственного интеллекта»**
Кластеризация

Студент гр. 5130904/30104

Руководитель

Аюпов Д. И.



Селин И. А.

Санкт-Петербург 2026

Задание 1

Постановка задачи


Разбейте множество объектов из набора данных pluton.csv на 3 кластера с помощью k means. Сравните качество разбиения в зависимости от максимального числа итераций алгоритма и использования стандартизации.

Ход работы

Построена кластеризация на 3 кластера. Для оценки качества кластеризации использовались следующие метрики:

- Силуэтный коэффициент (Silhouette Score): Измеряет, насколько объект похож на свой кластер по сравнению с другими. Значение варьируется от (-1) до (1) . Значение близкое к (1) означает, что кластеры плотные и хорошо разделены.
- Индекс Дэвиса-Болдуина (Davies-Bouldin Index): Оценивает среднее «сходство» между кластерами, где более низкие значения указывают на лучшее разделение.
- Метод локтя (Inertia/WCSS): Измеряет сумму квадратов расстояний от точек до центроидов кластеров. График должен напоминать «локоть», показывая момент, когда добавление кластеров перестает значительно улучшать результат.

Результаты



На первом графике видно, что инерция не подходит для сравнения так как сильно зависит от абсолютных значений изначальных данных. Согласно силуэтному коэффициенту и индексу Дэвиса-Болдуина стандартизация помогает получить лучшую кластеризацию. На всех графиках видно, что 3 итераций достаточно для кластеризации.


Задание 2


Постановка задачи

Разбейте на кластеры множество объектов из наборов данных clustering_1.csv, clustering_2.csv и clustering_3.csv с помощью k-means, DBSCAN и иерархической кластеризации. Определите оптимальное количество кластеров (где это применимо). Оцените с помощью метрик качество разбиения данных на кластеры. Визуализируйте разбиение на кластеры. Дайте собственную оценку по визуальному разбиению. Соответствует ли она оценке по метрикам? Какой из методов сработал лучше и почему?

Ход работы

Выполнены кластеризации 3 методами(KMeans, DBSCAN, AgglomerativeClustering), параметры(n_clusters для KMeans и AgglomerativeClustering, eps для DBSCAN) подбирались по наилучшему значению silhouette_score.





Результаты

```
silhouette_score for data1(KMeans, DBSCAN, AgglomerativeClustering):
0.5266153046388411, 0.23816761956968732, 0.5225656312659546
davies_bouldin_score for data1(KMeans, DBSCAN, AgglomerativeClustering):
0.7220548830860674, 0.531334643128683, 0.7279216570807387
n_of_clusters for data1(KMeans, DBSCAN, AgglomerativeClustering):
2, 1, 2
silhouette_score for data2(KMeans, DBSCAN, AgglomerativeClustering):
0.7066040396883444, 0.7066040396883444, 0.7066040396883444
davies_bouldin_score for data2(KMeans, DBSCAN, AgglomerativeClustering):
0.44498634618567107, 0.44498634618567107, 0.44498634618567107
n_of_clusters for data2(KMeans, DBSCAN, AgglomerativeClustering):
3, 3, 3
silhouette_score for data3(KMeans, DBSCAN, AgglomerativeClustering):
0.5118232189225244, 0.21599414953124288, 0.5000251644584494
davies_bouldin_score for data3(KMeans, DBSCAN, AgglomerativeClustering):
0.7450042806998424, 0.7571603914760298, 0.7509709719713269
n_of_clusters for data3(KMeans, DBSCAN, AgglomerativeClustering):
2, 3, 2
```

Для clustering_1.csv наилучшим оказалась кластеризация KMeans, AgglomerativeClustering тоже справилась успешно, а DBSCAN выделила 1 класс. Визуально KMeans и AgglomerativeClustering разделили данные на 2 кластера, которые в целом похожи, визуально сложно выделить лучший из них, в то время как DBSCAN не справилась совсем, это можно увидеть и в метриках, первые два метода имеют схожие коэффициенты, а последний худший результат silhouette_score. DBSCAN имеет лучший davies_bouldin_score из-за того, что разделил данные на один кластер и несколько точек шума, из-за чего получается средне-хорошее значение, хотя на самом деле алгоритм не смог разделить данные.

Для clustering_2.csv все кластеризации справились успешно. Это обусловлено тем, что изначальные точки легко разделимы по кластерам. Визуально мы видим три группы точек, которые методы и выделяют. Все метрики для всех методов имеют равные результаты, так как они разделили точки одинаково.

Для clustering_3.csv ни один метод кластеризации не смог выделить большой П-образный кластер, KMeans и AgglomerativeClustering не выделили нижний кластер, а DBSCAN смогла выделить его. Я бы назвал лучшим здесь DBSCAN, так как П-образный кластер не выделил никто, но нижний кластер осилил только DBSCAN. Но метрики не соответствуют визуальной оценке, так как основаны на расстояниях и длинные и изогнутые кластеры оцениваются как плохие.

DBSCAN плохо работает с кластерами разной плотности, из-за одинакового для всех кластеров значения ϵ . KMeans и AgglomerativeClustering плохо работают при кластерах сложных форм, в таком случае DBSCAN будет предпочтительнее.

Задание 3

Постановка задачи

Осуществите сжатие цветовой палитры изображения (любого, на ваш выбор). Для этого выделите n кластеров из цветов всех пикселей изображения и зафиксируйте центра этих кластеров. Создайте изображение с цветами из сокращенной палитры (цвета пикселей только из центров выделенных кластеров). Покажите исходное и сжатое изображения.

Ход работы

Использовалась кластеризация KMeans с палитрой на 8 цветов.

Результаты



Палитра из 8 цветов



Задание 4


Постановка задачи


Постройте дендрограмму для набора данных votes.csv (число голосов, поданных за республиканцев на выборах с 1856 по 1976 год). Строки представляют 50 штатов, а столбцы - годы выборов (31). Проинтерпретируйте полученный результат.

Ход работы

Выполнена иерархическая кластеризация, оптимальное число кластеров определялось по наибольшему силуэтному коэффициенту: k= 2: силуэт = 0.5061 k= 3: силуэт = 0.1775 k= 4: силуэт = 0.1745 k= 5: силуэт = 0.1862 k= 6: силуэт = 0.1763 k= 7: силуэт = 0.1870 k= 8: силуэт = 0.1888 k= 9: силуэт = 0.1964 k=10: силуэт = 0.1866.

Результаты





Область у графиков показывает стандартное отклонение внутри группы.

Получилось 2 кластера:

- **КЛАСТЕР 1:**

Количество объектов: 42

Средний % за республиканцев: 49.7%

Экстремальные годы: 1912(25.3%), 1920(60.7%), 1972(61.1%)

- **КЛАСТЕР 2:**

Количество объектов: 8

Средний % за республиканцев: 32.0%

Экстремальные годы: 1888(29.2%), 1892(20.4%), 1896(23.5%), 1900(23.2%), 1904(17.8%)

Кластеризация объектов (строк) показывает наличие устойчивых групп со схожим электоральным поведением на протяжении 120 лет (1856-1976). Оптимальное количество кластеров = 2.