

Министерство образования и науки РФ
Санкт-Петербургский политехнический университет Петра Великого
Институт компьютерных наук и кибербезопасности
Высшая школа программной инженерии

**Лабораторная работа по дисциплине «Системы
искусственного интеллекта»**
Ансамбли

Студент гр. 5130904/30104

Руководитель

Аюпов Д. И. 
Селин И. А. _____

Санкт-Петербург 2026

Задание 1

Постановка задачи

Исследуйте зависимость качества классификации от количества классификаторов в ансамбле для алгоритмов бэггинга на наборе данных glass.csv с различными базовыми классификаторами. Постройте графики зависимости качества классификации при различном числе классификаторов, объясните полученные результаты.

Ход работы

Бэггинг – технология классификации, где все элементарные классификаторы обучаются и работают параллельно (независимо друг от друга). Идея заключается в том, что классификаторы не исправляют ошибки друг друга, а компенсируют их при голосовании.

Созданы ансамбли на основе следующих классификаторов:


- DecisionTreeClassifier
- SVC
- KNeighborsClassifier,

со следующим количеством классификаторов:

[1, 5, 10, 15, 20, 30, 40, 50, 75, 100]

Отношение обучающей выборки к тестовой = 7/3

Результат



Базовый классификатор: Decision Tree

n= 1: Accuracy = 0.8000
n= 5: Accuracy = 0.8000
n= 10: Accuracy = 0.8308
n= 15: Accuracy = 0.8154
n= 20: Accuracy = 0.8000
n= 30: Accuracy = 0.8000
n= 40: Accuracy = 0.8154
n= 50: Accuracy = 0.8154

n= 75: Accuracy = 0.8154
n=100: Accuracy = 0.8154

Базовый классификатор: SVM (RBF)

n= 1: Accuracy = 0.7538
n= 5: Accuracy = 0.7692
n= 10: Accuracy = 0.7692
n= 15: Accuracy = 0.7846
n= 20: Accuracy = 0.7692
n= 30: Accuracy = 0.7692
n= 40: Accuracy = 0.7692
n= 50: Accuracy = 0.7692
n= 75: Accuracy = 0.7846
n=100: Accuracy = 0.7846

Базовый классификатор: KNN (k=5)

n= 1: Accuracy = 0.7538
n= 5: Accuracy = 0.7692
n= 10: Accuracy = 0.7538
n= 15: Accuracy = 0.7692
n= 20: Accuracy = 0.7538
n= 30: Accuracy = 0.7538
n= 40: Accuracy = 0.7538
n= 50: Accuracy = 0.7692
n= 75: Accuracy = 0.7692
n=100: Accuracy = 0.7692

Decision Tree:

- Качество при 1 классификаторе: 0.8000
- Максимальное качество: 0.8308 (при n=10)
- Улучшение: 3.8%

SVM (RBF):

- Качество при 1 классификаторе: 0.7538
- Максимальное качество: 0.7846 (при n=15)
- Улучшение: 4.1%

KNN (k=5):

- Качество при 1 классификаторе: 0.7538
- Максимальное качество: 0.7692 (при n=5)
- Улучшение: 2.0%

Задание 2

Постановка задачи

Исследуйте зависимость качества классификации от количества классификаторов в ансамбле для алгоритма бустинга (например, AdaBoost) на наборе данных vehicle.csv с различными базовыми классификаторами. Постройте графики зависимости качества классификации при различном числе классификаторов, объясните полученные результаты.

Ход работы

Бустинг (англ. boosting) — мета-алгоритм машинного обучения. Основной идеей бустинга является комбинирование слабых функций, которые строятся в ходе итеративного процесса,

где на каждом шаге новая модель обучается с использованием данных об ошибках предыдущих.

AdaBoost использует `sample_weight` для того, чтобы каждая следующая модель фокусировалась на ошибках предыдущей, этот параметр отсутствует у `SVC` и `KNeighborsClassifier`. Созданы ансамбли на основе следующих классификаторов:


- `Decision Tree(max_depth=1)`
- `Decision Tree(max_depth=2)`
- `Decision Tree(max_depth=5)`
- `Decision Tree(max_depth=10)`
- `Gaussian Naive Bayes`,

со следующим количеством классификаторов:

[1, 5, 10, 15, 20, 30, 40, 50, 75, 100]

Отношение обучающей выборки к тестовой = 7/3

Результат



Базовый классификатор: `Decision Tree(max_depth=1)`

n= 1: Accuracy = 0.3858
n= 5: Accuracy = 0.4134
n= 10: Accuracy = 0.3976
n= 15: Accuracy = 0.5906
n= 20: Accuracy = 0.6142
n= 30: Accuracy = 0.6220
n= 40: Accuracy = 0.6260
n= 50: Accuracy = 0.6181
n= 75: Accuracy = 0.5827
n=100: Accuracy = 0.6181

Базовый классификатор: `Decision Tree(max_depth=2)`

n= 1: Accuracy = 0.5669

n= 5: Accuracy = 0.6102
n= 10: Accuracy = 0.6772
n= 15: Accuracy = 0.6850
n= 20: Accuracy = 0.6417
n= 30: Accuracy = 0.6220
n= 40: Accuracy = 0.6614
n= 50: Accuracy = 0.6772
n= 75: Accuracy = 0.6457
n=100: Accuracy = 0.6457

Базовый классификатор: Decision Tree(max_depth=5)

n= 1: Accuracy = 0.7126
n= 5: Accuracy = 0.7362
n= 10: Accuracy = 0.7323
n= 15: Accuracy = 0.7402
n= 20: Accuracy = 0.7480
n= 30: Accuracy = 0.7638
n= 40: Accuracy = 0.7795
n= 50: Accuracy = 0.7598
n= 75: Accuracy = 0.7480
n=100: Accuracy = 0.7677

Базовый классификатор: Decision Tree(max_depth=10)

n= 1: Accuracy = 0.7047
n= 5: Accuracy = 0.7638
n= 10: Accuracy = 0.7638
n= 15: Accuracy = 0.7756
n= 20: Accuracy = 0.7638
n= 30: Accuracy = 0.7874
n= 40: Accuracy = 0.7756
n= 50: Accuracy = 0.7795
n= 75: Accuracy = 0.7598
n=100: Accuracy = 0.7598

Базовый классификатор: Gaussian Naive Bayes

n= 1: Accuracy = 0.4882
n= 5: Accuracy = 0.5591
n= 10: Accuracy = 0.5630
n= 15: Accuracy = 0.6457
n= 20: Accuracy = 0.6417
n= 30: Accuracy = 0.6969
n= 40: Accuracy = 0.6890
n= 50: Accuracy = 0.7441
n= 75: Accuracy = 0.7441
n=100: Accuracy = 0.7441

Decision Tree(max_depth=1):

- Качество при 1 классификаторе: 0.3858
- Максимальное качество: 0.6260 (при n=40)
- Улучшение: 62.2%

Decision Tree(max_depth=2):

- Качество при 1 классификаторе: 0.5669
- Максимальное качество: 0.6850 (при n=15)
- Улучшение: 20.8%

Decision Tree(max_depth=5):

- Качество при 1 классификаторе: 0.7126
- Максимальное качество: 0.7795 (при n=40)
- Улучшение: 9.4%

Decision Tree(max_depth=10):

- Качество при 1 классификаторе: 0.7047
- Максимальное качество: 0.7874 (при n=30)
- Улучшение: 11.7%

Gaussian Naïve Bayes:

- Качество при 1 классификаторе: 0.4882
- Максимальное качество: 0.7441 (при n=50)
- Улучшение: 52.4%

Задание 3

Постановка задачи

Постройте мета-классификатор для набора данных `titanic_train.csv` используя стекинг и оцените качество классификации на `titanic_test.csv`

Ход работы

Стекинг — это метод ансамблевого обучения в машинном обучении, который повышает точность прогнозов, объединяя предсказания нескольких разнородных базовых моделей с помощью мета-модели (обычно логистической регрессии), обучаемой на выходах базовых алгоритмов.

Базовыми моделями выбраны `DecisionTreeClassifier(max_depth=10)` и `SVC`. Мета-модель: `LogisticRegression`.

Результат

Доля выживших мужчин: 0.17293233082706766

Доля выживших женщин: 0.7171052631578947

В целом соответствует действительности, в реальности погибло 82% мужчин и 26% женщин.

Доля выживших 1 класса: 0.5887850467289719

Доля выживших 2 класса: 0.43010752688172044

Доля выживших 3 класса: 0.23853211009174313

В реальности 0.62, 0.41, 0.25 соответственно, тоже хорошая классификация.

Доля выживших с порта Cherbourg: 0.5294117647058824

Доля выживших с порта Southampton: 0.3

Доля выживших с порта Queenstown: 0.43478260869565216

Данные которые я нашел(не уверен в точности):

Распределение пассажиров по портам и классам (приблизительные данные):

- Саутгемптон (10 апреля): Большинство пассажиров поднялись на борт здесь — около 943 человек (из них 195 — 1-й класс, 255 — 2-й класс, остальные — 3-й).
- Шербур (10 апреля): На борт поднялись около 274 пассажиров (в основном 1-й класс, направлявшиеся в США).
- Квинстаун (11 апреля): На борт поднялись около 120 человек (в основном пассажиры 3-го класса).

В целом соответствует, модель правильно определила, лучший порт по выживаемости Шербур. Далее согласно найденной информации должен быть Саутгемптон, но получился Квинстаун. Предположение, что это связано с малым количеством пассажиров, что может вызвать статистические отклонения.



На этом графике видно, что стариков и детей спасали в первую очередь, у них выживших больше чем погибших, а в промежутке 16-45 наоборот.

В целом классификация удачная, данные соответствуют действительности.