

Министерство образования и науки РФ  
Санкт-Петербургский политехнический университет Петра Великого  
Институт компьютерных наук и кибербезопасности  
Высшая школа программной инженерии

**Лабораторная работа по дисциплине «Системы  
искусственного интеллекта»**  
Кластеризация

Студент гр. 5130904/30104

Руководитель

Аюпов Д. И. \_\_\_\_\_

Селин И. А. \_\_\_\_\_

Санкт-Петербург 2026

## Задание 1

### Постановка задачи

Исследуйте зависимость качества классификации от количества классификаторов в ансамбле для алгоритмов бэггинга на наборе данных glass.csv с различными базовыми классификаторами. Постройте графики зависимости качества классификации при различном числе классификаторов, объясните полученные результаты.

### Ход работы

Бэггинг – технология классификации, где все элементарные классификаторы обучаются и работают параллельно (независимо друг от друга). Идея заключается в том, что классификаторы не исправляют ошибки друг друга, а компенсируют их при голосовании. Созданы ансамбли на основе следующих классификаторов:


- DecisionTreeClassifier
- SVC
- KNeighborsClassifier,

со следующим количеством классификаторов:

[1, 5, 10, 15, 20, 30, 40, 50, 75, 100]

Отношение обучающей выборки к тестовой = 7/3

### Результат



Базовый классификатор: Decision Tree

n= 1: Accuracy = 0.8000  
n= 5: Accuracy = 0.8000  
n= 10: Accuracy = 0.8308  
n= 15: Accuracy = 0.8154  
n= 20: Accuracy = 0.8000  
n= 30: Accuracy = 0.8000  
n= 40: Accuracy = 0.8154  
n= 50: Accuracy = 0.8154

n= 75: Accuracy = 0.8154  
n=100: Accuracy = 0.8154

Базовый классификатор: SVM (RBF)

n= 1: Accuracy = 0.7538  
n= 5: Accuracy = 0.7692  
n= 10: Accuracy = 0.7692  
n= 15: Accuracy = 0.7846  
n= 20: Accuracy = 0.7692  
n= 30: Accuracy = 0.7692  
n= 40: Accuracy = 0.7692  
n= 50: Accuracy = 0.7692  
n= 75: Accuracy = 0.7846  
n=100: Accuracy = 0.7846

Базовый классификатор: KNN (k=5)

n= 1: Accuracy = 0.7538  
n= 5: Accuracy = 0.7692  
n= 10: Accuracy = 0.7538  
n= 15: Accuracy = 0.7692  
n= 20: Accuracy = 0.7538  
n= 30: Accuracy = 0.7538  
n= 40: Accuracy = 0.7538  
n= 50: Accuracy = 0.7692  
n= 75: Accuracy = 0.7692  
n=100: Accuracy = 0.7692

Decision Tree:

- Качество при 1 классификаторе: 0.8000
- Максимальное качество: 0.8308 (при n=10)
- Улучшение: 3.8%

SVM (RBF):

- Качество при 1 классификаторе: 0.7538
- Максимальное качество: 0.7846 (при n=15)
- Улучшение: 4.1%

KNN (k=5):

- Качество при 1 классификаторе: 0.7538
- Максимальное качество: 0.7692 (при n=5)
- Улучшение: 2.0%

## Задание 2

### Постановка задачи

Исследуйте зависимость качества классификации от количества классификаторов в ансамбле для алгоритма бустинга (например, AdaBoost) на наборе данных vehicle.csv с различными базовыми классификаторами. Постройте графики зависимости качества классификации при различном числе классификаторов, объясните полученные результаты.

### Ход работы

Бустинг (англ. boosting) — мета-алгоритм машинного обучения. Основной идеей бустинга является комбинирование слабых функций, которые строятся в ходе итеративного процесса,

где на каждом шаге новая модель обучается с использованием данных об ошибках предыдущих.

AdaBoost использует `sample_weight` для того, чтобы каждая следующая модель фокусировалась на ошибках предыдущей, этот параметр отсутствует у SVC и KNeighborsClassifier. Созданы ансамбли на основе следующих классификаторов:


- Decision Tree(max\_depth=1)
- Decision Tree(max\_depth=2)
- Decision Tree(max\_depth=5)
- Decision Tree(max\_depth=10)
- Gaussian Naive Bayes,

со следующим количеством классификаторов:

[1, 5, 10, 15, 20, 30, 40, 50, 75, 100]

Отношение обучающей выборки к тестовой = 7/3

## Результат



Базовый классификатор: Decision Tree(max\_depth=1)

n= 1: Accuracy = 0.3858  
n= 5: Accuracy = 0.4134  
n= 10: Accuracy = 0.3976  
n= 15: Accuracy = 0.5906  
n= 20: Accuracy = 0.6142  
n= 30: Accuracy = 0.6220  
n= 40: Accuracy = 0.6260  
n= 50: Accuracy = 0.6181  
n= 75: Accuracy = 0.5827  
n=100: Accuracy = 0.6181

Базовый классификатор: Decision Tree(max\_depth=2)

n= 1: Accuracy = 0.5669

n= 5: Accuracy = 0.6102  
n= 10: Accuracy = 0.6772  
n= 15: Accuracy = 0.6850  
n= 20: Accuracy = 0.6417  
n= 30: Accuracy = 0.6220  
n= 40: Accuracy = 0.6614  
n= 50: Accuracy = 0.6772  
n= 75: Accuracy = 0.6457  
n=100: Accuracy = 0.6457

Базовый классификатор: Decision Tree(max\_depth=5)

n= 1: Accuracy = 0.7126  
n= 5: Accuracy = 0.7362  
n= 10: Accuracy = 0.7323  
n= 15: Accuracy = 0.7402  
n= 20: Accuracy = 0.7480  
n= 30: Accuracy = 0.7638  
n= 40: Accuracy = 0.7795  
n= 50: Accuracy = 0.7598  
n= 75: Accuracy = 0.7480  
n=100: Accuracy = 0.7677

Базовый классификатор: Decision Tree(max\_depth=10)

n= 1: Accuracy = 0.7047  
n= 5: Accuracy = 0.7638  
n= 10: Accuracy = 0.7638  
n= 15: Accuracy = 0.7756  
n= 20: Accuracy = 0.7638  
n= 30: Accuracy = 0.7874  
n= 40: Accuracy = 0.7756  
n= 50: Accuracy = 0.7795  
n= 75: Accuracy = 0.7598  
n=100: Accuracy = 0.7598

Базовый классификатор: Gaussian Naive Bayes

n= 1: Accuracy = 0.4882  
n= 5: Accuracy = 0.5591  
n= 10: Accuracy = 0.5630  
n= 15: Accuracy = 0.6457  
n= 20: Accuracy = 0.6417  
n= 30: Accuracy = 0.6969  
n= 40: Accuracy = 0.6890  
n= 50: Accuracy = 0.7441  
n= 75: Accuracy = 0.7441  
n=100: Accuracy = 0.7441

Decision Tree(max\_depth=1):

- Качество при 1 классификаторе: 0.3858
- Максимальное качество: 0.6260 (при n=40)
- Улучшение: 62.2%

Decision Tree(max\_depth=2):

- Качество при 1 классификаторе: 0.5669
- Максимальное качество: 0.6850 (при n=15)
- Улучшение: 20.8%

Decision Tree(max\_depth=5):

- Качество при 1 классификаторе: 0.7126
- Максимальное качество: 0.7795 (при n=40)
- Улучшение: 9.4%

Decision Tree(max\_depth=10):

- Качество при 1 классификаторе: 0.7047
- Максимальное качество: 0.7874 (при n=30)
- Улучшение: 11.7%

Gaussian Naïve Bayes:

- Качество при 1 классификаторе: 0.4882
- Максимальное качество: 0.7441 (при n=50)
- Улучшение: 52.4%

### Задание 3

#### Постановка задачи

Постройте мета-классификатор для набора данных titanic\_train.csv используя стекинг и оцените качество классификации на titanic\_test.csv

#### Ход работы

Стекинг — это метод ансамблевого обучения в машинном обучении, который повышает точность прогнозов, объединяя предсказания нескольких разнородных базовых моделей с помощью мета-модели (обычно логистической регрессии), обучаемой на выходах базовых алгоритмов.

Базовыми моделями выбраны DecisionTreeClassifier(max\_depth=10) и SVC. Мета-модель: LogisticRegression.

#### Результат

Доля выживших мужчин: 0.17293233082706766

Доля выживших женщин: 0.7171052631578947

В целом соответствует действительности, в реальности погибло 82% мужчин и 26% женщин.

Доля выживших 1 класса: 0.5887850467289719

Доля выживших 2 класса: 0.43010752688172044

Доля выживших 3 класса: 0.23853211009174313

В реальности 0.62, 0.41, 0.25 соответственно, тоже хорошая классификация.

Доля выживших с порта Cherbourg: 0.5294117647058824

Доля выживших с порта Southampton: 0.3


Доля выживших с порта Queenstown: 0.43478260869565216

Данные которые я нашел(не уверен в точности):

Распределение пассажиров по портам и классам (приблизительные данные):

- Саутгемптон (10 апреля): Большинство пассажиров поднялись на борт здесь — около 943 человек (из них 195 — 1-й класс, 255 — 2-й класс, остальные — 3-й).
- Шербур (10 апреля): На борт поднялись около 274 пассажиров (в основном 1-й класс, направлявшиеся в США).
- Квинстаун (11 апреля): На борт поднялись около 120 человек (в основном пассажиры 3-го класса).

В целом соответствует, модель правильно определила, лучший порт по выживаемости Шербур. Далее согласно найденной информации должен быть Саутгемптон, но получился Квинстаун. Предположение, что это связано с малым количеством пассажиров, что может вызвать статистические отклонения.



На этом графике видно, что стариков и детей спасали в первую очередь, у них выживших больше чем погибших, а в промежутке 16-45 наоборот.

В целом классификация удачная, данные соответствуют действительности.