

Министерство образования и науки РФ  
Санкт-Петербургский политехнический университет Петра Великого  
Институт компьютерных наук и кибербезопасности  
Высшая школа программной инженерии

**Лабораторная работа по дисциплине «Системы  
искусственного интеллекта»**  
Линейная регрессия

Студент гр. 5130904/30104

Руководитель

Аюпов Д. И. \_\_\_\_\_

Селин И. А. \_\_\_\_\_

Санкт-Петербург 2026

## Задание 1

### Постановка задачи

Загрузите данные из файла reglab1.txt. Постройте по набору данных линейные регрессии, используя модели с различными зависимыми переменными. Выберите наиболее подходящую модель.

### Ход работы

Линейная регрессия — метод нахождения линейной зависимости между зависимой переменной  $Y$  и независимыми переменными  $X$ .

Качество моделей я оценил по следующим метрикам:

- $R^2$  (чем ближе к 1, тем лучше)
- Adj.  $R^2$  ( $R^2$  с поправкой на число признаков)
- RSS (чем меньше, тем лучше)

### Результат

Модель 1:  $Y = \text{col0}$ ,  $X$  = остальные

Уравнение:  $\text{col0} = -0.0216 + (4.1025) \cdot \text{col1} + (4.9431) \cdot \text{col2}$

$R^2 = 0.968629$ , Adj.  $R^2 = 0.968310$ , RSS = 22.456893

Модель 2:  $Y = \text{col1}$ ,  $X$  = остальные

Уравнение:  $\text{col1} = 0.0455 + (0.2239) \cdot \text{col0} + (-1.1059) \cdot \text{col2}$

$R^2 = 0.918668$ , Adj.  $R^2 = 0.917842$ , RSS = 1.225770

Модель 3:  $Y = \text{col2}$ ,  $X$  = остальные

Уравнение:  $\text{col2} = 0.0286 + (0.1923) \cdot \text{col0} + (-0.7882) \cdot \text{col1}$

$R^2 = 0.950528$ , Adj.  $R^2 = 0.950025$ , RSS = 0.873605


=====

Наиболее подходящая модель:  $Y = \text{col0}$

$R^2 = 0.968629$

Adj.  $R^2 = 0.968310$

RSS = 22.456893 (больше чем в других соделах из-за большого абсолютного значения в 0 столбце)



## Задание 2

### Постановка задачи

Реализуйте следующий алгоритм для уменьшения количества признаков, используемых для построения регрессии: для каждого  $k \in \{0, 1, \dots, d\}$  выбрать подмножество признаков мощности  $k^1$ , минимизирующее остаточную сумму квадратов RSS. Используя полученный алгоритм, выберите оптимальное подмножество признаков для данных из файла reglab.txt.

Объясните свой выбор. Использование всех 4 признаков не уменьшает количество признаков, их должно быть меньше.

### Ход работы

rss\_k0: 394.67

rss\_k1: 157.21, 268.24, 393.49, 394.59

rss\_k2: 0.53, 156.35, 157.21, 267.79, 267.80, 393.45

rss\_k3: 0.33, 0.36, 156.34, 267.44

### Результат

Выбор оптимального подмножества

Оптимальное подмножество: x1, x2 (k = 2)

Обоснование выбора:

- RSS уменьшается с 394.68 (без признаков) до 0.5380 (x1, x2) — улучшение в 734 раза
- Добавление третьего признака (x3) снижает RSS незначительно: с 0.5380 до 0.3323 (улучшение всего на 0.2057)

Закон убывающей отдачи:

- k=0 → k=1: улучшение на 237.46
- k=1 → k=2: улучшение на 156.68 (всё ещё значительное)
- k=2 → k=3: улучшение всего на 0.21 (незначительное)

### Задание 3

#### Постановка задачи

Загрузите данные из файла `sygaxe.txt`. Постройте регрессию, выражающую зависимость возраста исследуемых отложений от глубины залегания, используя веса наблюдений. Сравните с моделью, не учитывающей веса наблюдений. Оцените качество построенной модели.

#### Ход работы

ОБЫЧНАЯ РЕГРЕССИЯ (без весов):

Уравнение:  $\text{age} = 1693.0714 + 20.6746 * \text{depth}$

$R^2 = 0.959256$

RSS = 10526389.029524

ВЗВЕШЕННАЯ РЕГРЕССИЯ (с весами из файла):

Уравнение:  $\text{age} = 784.5699 + 21.9092 * \text{depth}$

$R^2$  (взвешенный) = 0.973684

RSS (взвешенный) = 592594.422642

### Результат

Оценка качества взвешенной модели

1.  $R^2 = 0.9737$  (отлично)

- Модель объясняет 97.37% дисперсии зависимой переменной
- Это очень высокий показатель (близок к 1)
- Улучшение по сравнению с обычной моделью (95.93% → 97.37%)

2. RSS = 592594 (хорошо)

- Взвешенная сумма квадратов ошибок значительно ниже
- Учитывая, что RSS обычной модели был 17.8 раз больше, веса сыграли ключевую роль

## Задание 4

### Постановка задачи

Загрузите данные из файла longley.csv. Данные состоят из 7 экономических переменных, наблюдаемых с 1947 по 1962 годы (n=16). Исключите переменную Population. Разделите данные на тестовую и обучающую выборки равных размеров случайным образом.

Постройте линейную регрессию по признаку Employed.

Постройте гребневую регрессию для значений  $\lambda = 10^{-3+0.2 \cdot i}$ ,  $i = 0, \dots, 25$ . Подсчитайте ошибку на тестовой и обучающей выборке для линейной регрессии и гребневой регрессии на данных значениях  $\lambda$ , постройте графики. Объясните полученные результаты.


### Ход работы

Гребневая регрессия (ridge regression) — это метод регуляризации линейной модели, который борется с мультиколлинеарностью (высокой корреляцией признаков) и переобучением, добавляя штраф за большие коэффициенты.

Качество работы модели я решил оценивать по коэффициенту детерминации ( $R^2$ ).

### Результат

```
r2 for linear regression = 0.95385695567627
r2 for ridge regression:
lambda = 0.001: 0.9570062882882389
lambda = 0.001584893192461114: 0.9586946684494675
lambda = 0.0025118864315095794: 0.9611610472497321
lambda = 0.003981071705534973: 0.9646025622691905
lambda = 0.00630957344480193: 0.9690782635511092
lambda = 0.01: 0.9743046606947083
lambda = 0.01584893192461114: 0.9794686290072441
lambda = 0.025118864315095808: 0.9833146040389736
lambda = 0.039810717055349734: 0.9847133432555665
lambda = 0.06309573444801933: 0.983412535184314
lambda = 0.1: 0.9802325278640295
lambda = 0.15848931924611143: 0.9764649278666425
lambda = 0.25118864315095824: 0.9730905555285121
lambda = 0.3981071705534973: 0.9704451589741336
lambda = 0.6309573444801936: 0.9683822767655376
lambda = 1.0: 0.9666377961990361
lambda = 1.584893192461114: 0.9650895922462372
lambda = 2.5118864315095824: 0.9637791922707777
lambda = 3.981071705534973: 0.9627917176051688
lambda = 6.309573444801936: 0.9621590593969499
lambda = 10.0: 0.96184650127446
lambda = 15.848931924611142: 0.9617896917745716
lambda = 25.11886431509582: 0.9619370950470645
lambda = 39.81071705534978: 0.9622762967715681
lambda = 63.09573444801943: 0.9628441501113792
lambda = 100.0: 0.9637298517212823
best r2 for ridge: 0.9847133432555665
best i for ridge: 8, lambda = 0.039810717055349734
```



В начале при малом  $i$  и  $\lambda$  соответственно:

- маленькая регуляризация убирает нестабильность коэффициентов
- модель становится устойчивее
- переобучение уменьшается

Далее:

- регуляризация начинает слишком сильно сжимать коэффициенты
- модель теряет полезную информацию
- появляется недообучение

В конце:

- коэффициенты уже почти “обнулены”
- дальнейшее увеличение  $\lambda$  почти не меняет модель
- $R^2$  выходит на плато 0.963


## Задание 5

### Постановка задачи

Загрузите данные из файла eustock.csv. Данные содержат ежедневные котировки на момент закрытия фондовых бирж: Germany DAX (Ibis), Switzerland SMI, France CAC, и UK FTSE. Постройте на одном графике все кривые изменения котировок во времени. Постройте линейную регрессию для каждой модели в отдельности и для всех моделей вместе. Оцените, какая из бирж имеет наибольшую динамику численно (не на основе анализа графиков).

### Ход работы

Построенно пять линейных регрессий, для каждой биржи и усредненное значение и график к каждому предсказанию.



## Результат

По графику видно, что наибольшая динамика у SMI, а наименьшая у CAC. Коэффициенты  $b$  для каждого из графиков: Коэффициенты динамики ( $b$ ):

DAX: 1.7294

SMI: 2.7598

CAC: 0.7868

FTSE: 1.6748

Common: 1.7377


## Задание 6

### Постановка задачи

Загрузите данные из файла JohnsonJohnson.csv. Данные содержат поквартальную прибыль компании Johnson & Johnson с 1960 по 1980 гг. Постройте на одном графике все кривые изменения прибыли во времени. Постройте линейную регрессию для каждого квартала в отдельности и для всех кварталов вместе. Оцените, в каком квартале компания имеет наибольшую и наименьшую динамику доходности. Сделайте прогноз по прибыли в 2016 году во всех кварталах и в среднем по году.

### Ход работы

Построено пять линейных регрессий, для каждого квартала и усредненное значение и график к каждому предсказанию.



## Результат

Коэффициенты динамики (b):

Q1: 0.6950

Q2: 0.6853

Q3: 0.7044

Q4: 0.5349

Average: 0.6549

Наибольшая динамика в Q3, наименьшая в Q4 Predicts in 2016:

Q1: [36.75963636]

Q2: [36.48945455]

Q2: [37.65393939]

Q2: [28.79391342]


Avg: [34.92423593]

## Задание 7

### Постановка задачи

Загрузите данные из файла cars.csv. Данные содержат зависимости тормозного пути автомобиля (футы) от его скорости (мили в час). Данные получены в 1920 г. Постройте регрессионную модель, визуализируйте её и оцените длину тормозного пути при скорости 40 миль в час.

## Ход работы



## Результат

40 mph: 139.71725547 m

При маленькой скорости тормозной путь меньше 0.


## Задание 8

### Постановка задачи

Загрузите данные из файла `svmdata6.txt`. Постройте регрессионный алгоритм метода опорных векторов (`sklearn.svm.SVR`) с параметром  $C = 1$ , используя ядро "rbf". Отобразите на графике зависимость среднеквадратичной ошибки на обучающей выборке от значения параметра  $\epsilon$ . Прокомментируйте полученный результат



## Ход работы



$\epsilon = 0.01$ , MSE = 0.010914

$\epsilon = 0.05$ , MSE = 0.010872

$\epsilon = 0.10$ , MSE = 0.011055

$\epsilon = 0.20$ , MSE = 0.013580

$\epsilon = 0.30$ , MSE = 0.026504

$\epsilon = 0.50$ , MSE = 0.067863

$\epsilon = 0.70$ , MSE = 0.145871

$\epsilon = 1.00$ , MSE = 0.344611

$\epsilon = 1.50$ , MSE = 0.537395

$\epsilon = 2.00$ , MSE = 0.537395

## Результат

Оптимальное  $\epsilon = 0.05$ , MSE = 0.010872

1. Оптимальное  $\epsilon = 0.05$

При этом значении MSE минимальна (0.01087). Это наилучший компромисс между точностью и обобщающей способностью модели.

2. При  $\epsilon < 0.05$  (0.01)

MSE чуть выше (0.01091). Модель пытается слишком точно следовать за данными — появляется лёгкое переобучение.

3. При  $\epsilon > 0.05$  (0.1  $\rightarrow$  0.5)

MSE начинает расти. Модель становится слишком грубой — недообучение.

4. При  $\epsilon > 0.5$

MSE взлетает до 0.54. Модель почти не учитывает данные, предсказания очень неточные.

## Задание 9

### Постановка задачи

Загрузите набор данных из файла nsw74psid1.csv. Постройте регрессионное дерево (sklearn.tree.DecisionTreeRegressor) для признака re78. Постройте линейную регрессионную модель и SVM-регрессию для этого набора данных. Сравните качество построенных моделей, выберите оптимальную модель и объясните свой выбор.

### Ход работы

Дерево решений:

MSE: 116888620.67

$R^2$ : 0.5254

Линейная регрессия:

MSE: 103001507.33

$R^2$ : 0.5818

SVR:

MSE: 243915552.84

$R^2$ : 0.0097

### Результат

По  $R^2$  лучшая модель: Линейная регрессия ( $R^2 = 0.5818$ )

По MSE лучшая модель: Линейная регрессия (MSE = 103001507.33)